

Análise experimental de modelos matemáticos propostos para o problema da Árvore geradora multiobjetivo baseada no operador OWA

Prof^a. Dr^a. Elizabeth Ferreira Gouvêa Goldberg
Islame Felipe da Costa Fernandes

Departamento de Informática e Matemática Aplicada - DIMAp
Universidade Federal do Rio Grande do Norte - UFRN

Natal, 05 setembro de 2017

Agenda

- 1 Introdução
- 2 O problema
- 3 Os modelos
- 4 Experimentos computacionais
- 5 Considerações finais e trabalhos complementares

Introdução

- 1 Abordaremos a Árvore Geradora Multiobjetivo com critério OWA.
- 2 Objetivos do trabalho: implementar, experimentar e analisar os resultados dos modelos de programação linear de Galand e Spanjaard (2012) e o de Fernández et al. (2017)
- 3 Serão relatados experimentos para 39 grafos completos, de 5 a 35 vértices, das classes *correlated* e *anti-correlated* para 3 e 4 objetivos.
- 4 O presente trabalho justifica-se, pois, diante da proposta de conduzir novos experimentos em classes de instâncias *correlated* e *anti-correlated* conforme proposto por Knowles (2002).

Notação Importante

- ❶ $G(V, E)$, $|V| = n$, $|E| = m$
- ❷ $P = \{1, 2, \dots, p\}$ um conjunto com p objetivos
- ❸ $c_e = (c_e^1, \dots, c_e^p)^T \in \mathbb{R}^p$ vetor de custos associado a cada aresta $e \in E$
- ❹ Seja $C \in \mathbb{R}^{p \times m}$ tal que:

$$C = \begin{pmatrix} c_{e_1}^1 & c_{e_2}^1 & \dots & c_{e_m}^1 \\ c_{e_1}^2 & c_{e_2}^2 & \dots & c_{e_m}^2 \\ \dots & \dots & \dots & \dots \\ c_{e_1}^p & c_{e_2}^p & \dots & c_{e_m}^p \end{pmatrix}$$

- ❺ $X \subseteq \{0, 1\}^m$ o conjunto de árvores geradoras de G
- ❻ $\tau \in X$ um vetor, de dimensão m ;
- ❼ $Z \subseteq \mathbb{R}^p$ o espaço objetivo
- ❽ $f : X \rightarrow Z$ tal que $f(\tau) = C\tau$
- ❾ $f_i(\tau) = C_i\tau$

O problema da *MoST*

Vocês já sabem que...

O problema da *MoST* visa encontrar o conjunto de árvores eficientes $X^* \subseteq X$, dito conjunto Pareto ótimo, com $f(X^*) \subseteq Z$, chamada Fronteira de Pareto.

O problema da OWA-ST

- 1 *Ordered Weighted Average (OWA)*
- 2 Seja $\forall \tau \in X$, $f_\sigma(\tau) \in Z$ o vetor que permuta os custos componentes do vetor $f(\tau)$ tal que $f_{\sigma_1}(\tau) \geq \dots \geq f_{\sigma_p}(\tau)$.
- 3 Seja ainda $\omega \in \mathbb{R}^p$ um vetor de pesos não negativos tais que $\sum_{i \in P} \omega_i = 1$.
- 4 O problema OWA-ST visa encontrar $\tau \in X$ que minimiza o operador $OWA_\omega(\tau) = \omega^T f_\sigma(\tau)$.
- 5 O problema OWA-ST é NP-Difícil (GALAND; SPANJAARD, 2012; FERNÁNDEZ et al., 2017)

Estado da arte do operador de *OWA*

- 1 Vocês já conhecem boa parte do estado da arte da *MoST*
- 2 O *OWA* foi introduzido por Yager (1988) e pode ser adotado como preferência em qualquer problema multicritério
- 3 Trabalhos de Ogryczak e Śliwiński (2003), Fernández, Pozo e Puerto (2014) e Chassein e Goerigk (2015)
- 4 Operador *OWA fuzzy* aplicado a classificadores: Wang, Zhang e Qian (2011) e Ramentol et al. (2015)
- 5 Operador *OWA fuzzy* em *engine* de pesquisas em rede De e Diaz (2011)

Modelo de Galand e Spanjaard (2012)

$$z_{ij} = \begin{cases} 1 & \text{se a } i\text{-ésima função objetivo ocupa posição } j \\ 0 & \text{caso contrário} \end{cases}$$

$$\text{Min} \sum_{j \in P} \omega_j \left(\sum_{i \in P} r_{ij} \right) \quad (1)$$

Sujeito a:

$$\sum_{i \in P} z_{ij} = 1 \quad \forall j \in P \quad (2)$$

$$\sum_{j \in P} z_{ij} = 1 \quad \forall i \in P \quad (3)$$

$$\sum_{i \in P} r_{ij} \geq \sum_{i \in P} r_{ij+1} \quad j \in P : j < p \quad (4)$$

$$r_{ij} \leq M z_{ij} \quad i, j \in P \quad (5)$$

$$\sum_{j \in P} r_{ij} = C_i \tau \quad i \in P \quad (6)$$

$$\tau \in X \quad (7)$$

$$r_{ij} \geq 0 \quad i, j \in P \quad (8)$$

$$z \in \{0, 1\}^{p \times p} \quad (9)$$

Modelo de Fernández et al. (2017)

$$z_{ij} = \begin{cases} 1 & \text{se a } i\text{-ésima função objetivo ocupa posição } j \\ 0 & \text{caso contrário} \end{cases}$$

$$\text{Min } \sum_{j \in P} \omega_j \theta_j \quad (10)$$

Sujeito a:

$$\sum_{i \in P} z_{ij} = 1 \quad \forall j \in P \quad (11)$$

$$\sum_{j \in P} z_{ij} = 1 \quad \forall i \in P \quad (12)$$

$$C_i \tau \leq \theta_j + M \left(1 - \sum_{k \geq j} z_{ik} \right) \quad i, j \in P \quad (13)$$

$$\theta_j \geq \theta_{j+1} \quad j \in P : j < p \quad (14)$$

$$\tau \in X \quad (15)$$

$$\theta_j \geq 0 \quad j \in P \quad (16)$$

$$z \in \{0, 1\}^{p \times p} \quad (17)$$

Modelo de MST de Magnanti e Wong (1984)

$$y_{ij} = \begin{cases} 1 & \text{se a aresta } (i,j) \in E \text{ é utilizada para transporte do fluxo} \\ 0 & \text{caso contrário} \end{cases}$$

x_{ij} : é a quantidade de fluxo transportado do nó i ao nó j pela aresta $(i,j) \in E$.

$$\begin{aligned} \text{Min} \quad & \sum_{\{(i,j) \in E\}} c_{ij} y_{ij} \\ & \sum_{\{j: (1,j) \in E\}} x_{1j} = n - 1 \end{aligned} \tag{18}$$

$$\sum_{\{i: (i,j) \in E\}} x_{ij} - \sum_{\{k: (j,k) \in E\}} x_{jk} = 1 \quad \forall j = 2, 3, \dots, n \tag{19}$$

$$x_{ij} \geq 0 \quad \forall (i,j) \in E \tag{20}$$

$$(n - 1)y_{ij} \geq x_{ij} \quad \forall (i,j) \in E \tag{21}$$

$$y_{ij} \leq x_{ij} \quad \forall (i,j) \in E \tag{22}$$

$$y_{ij} \in \{0, 1\} \quad \forall (i,j) \in E \tag{23}$$

Instâncias

- ① 39 instâncias
- ② 5 a 35 vértices
- ③ 3 e 4 objetivos
- ④ 3 grupos de instâncias: $n.1$, $n.2$, $n.3$
- ⑤ Classes: *correlated* e *anti-correlated* (KNOWLES, 2002)
 - ① *correlated* Coeficientes dos respectivos grupos: 0.2, 0.5 e 0.85
 - ② *anti-correlated* Coeficientes dos respectivos grupos: -0.2, -0.5 e -0.85
- ⑥ Critério do operador OWA
 - ① Determinar $k \in P$ e gerar os pesos tais que $\omega_1 = \dots = \omega_k = 1/k$ e $\omega_{k+1} = \dots = \omega_p = 0$.


Metodologia dos experimentos

- ① Limite de tempo: 10800 segundos;
- ② Observação:
 - ① Tempo;
 - ② *gap* entre a solução relaxada inicial e a melhor solução encontrada

$$100(z^* - z_R)/z_R \quad (24)$$


- ③ Quantidade de nós do *Branch-and-bound*

Resultados para 3 objetivos : Limite de 3 horas




Resultados para 3 objetivos : Curva de crescimento do tempo

Curvas de crescimento do tempo médio em função do tamanho da instância correlated com 3 objetivos




Curvas de crescimento do tempo médio em função do tamanho da instância anti-correlated com 3 objetivos




Resultados para 3 objetivos : Tempo computacional

Porcentagem de instâncias correlated com 3 objetivos em que cada algoritmo foi melhor que o outro (tempo computacional)



Aqui houve ainda 5.1% de instâncias correlated onde FER atingiu 3 horas, mas GS não atingiu. Todas as instâncias em que GS atingiu 3 horas, FER também atingiu.


Porcentagem de instâncias anti-correlated com 3 objetivos em que cada algoritmo foi melhor que o outro (tempo computacional)



Ambos os modelos atingiram o tempo limite em exatamente as mesmas instâncias


Resultados para 3 objetivos : Gap da solução inicial

Porcentagem de instâncias correlated com 3 objetivos em que cada modelo conseguiu menor gap ao fim de 3 horas



Este cálculo foi feito em cima dos 51.3 % das instâncias correlated em que ambos atingiram 3 horas


Porcentagem de instâncias anti-correlated com 3 objetivos em que cada modelo conseguiu menor gap ao fim de 3 horas




Este cálculo foi feito em cima dos 74.36 % das instâncias anti-correlated em que ambos atingiram 3 horas

Resultados para 3 objetivos : Gap da solução inicial

Curvas de crescimento do Gap médio em função do tamanho da instância correlated com 3 objetivos




Curvas de crescimento do Gap médio em função do tamanho da instância anti-correlated com 3 objetivos




Resultados para 3 objetivos : Quantidade de nós do B&B


Cálculo efetuado sobre o total de instâncias correlated em que ambos os modelos atingiram 3 horas



Cálculo efetuado sobre o total de instâncias correlated em que ambos os modelos terminaram



Porcentagem de instâncias correlated com 3 objetivos em que cada algoritmo utilizou a menor quantidade de nós do Branch-and-bound




● GS utilizou menor quantidade de nós
● FER utilizou menor quantidade de nós


● GS utilizou menor quantidade de nós
● FER utilizou menor quantidade de nós

Resultados para 3 objetivos : Quantidade de nós do B&B


Cálculo efetuado sobre o total de instâncias anti-correlated em que ambos os modelos atingiram 3 horas



Cálculo efetuado sobre o total de instâncias anti-correlated em que ambos os modelos terminaram




Porcentagem de instâncias anti-correlated com 3 objetivos em que cada algoritmo utilizou a menor quantidade de nós do Branch-and-bound




● GS utilizou menor quantidade de nós
● FER utilizou menor quantidade de nós

Resultados para 3 objetivos : Quantidade de nós do B&B

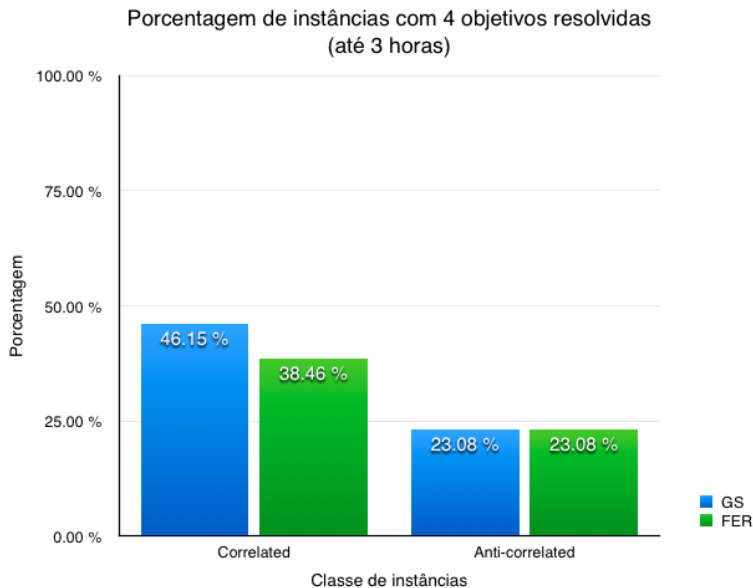
Curvas de crescimento da quantidade média de nós em função do tamanho das instâncias correlated com 3 objetivos



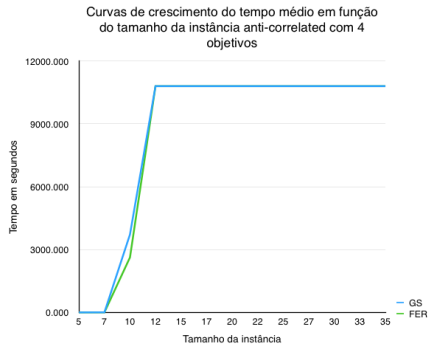

Curvas de crescimento da quantidade média de nós em função do tamanho das instâncias anti-correlated com 3 objetivos



Resultados para 4 objetivos : Limite de 3 horas




Resultados para 4 objetivos : Curva de crescimento do tempo




Resultados para 4 objetivos : Tempo computacional

Porcentagem de instâncias correlated com 4 objetivos em que cada algoritmo foi melhor que o outro (tempo computacional)



Aqui houve ainda 7.7% de instâncias correlated onde FER atingiu 3 horas, mas GS não atingiu. Todas as instâncias em que GS atingiu 3 horas, FER também atingiu.


Porcentagem de instâncias anti-correlated com 4 objetivos em que cada algoritmo foi melhor que o outro (tempo computacional)



Ambos os modelos atingiram o tempo limite em exatamente as mesmas instâncias


Resultados para 4 objetivos : Gap da solução inicial

Porcentagem de instâncias correlated com 4 objetivos em que cada modelo conseguiu menor gap ao fim de 3 horas



Este cálculo foi feito em cima dos 53,85 % das instâncias correlated em que ambos atingiram 3 horas


Porcentagem de instâncias anti-correlated com 4 objetivos em que cada modelo conseguiu menor gap ao fim de 3 horas




Este cálculo foi feito em cima dos 76,92 % das instâncias anti-correlated em que ambos atingiram 3 horas

Resultados para 4 objetivos : Gap da solução inicial

Curvas de crescimento do Gap médio em função do tamanho da instância correlated com 4 objetivos




Curvas de crescimento do Gap médio em função do tamanho da instância anti-correlated com 4 objetivos




Resultados para 4 objetivos : Quantidade de nós do B&B


Cálculo efetuado sobre o total de instâncias correlated em que ambos os modelos atingiram 3 horas



Cálculo efetuado sobre o total de instâncias correlated em que ambos os modelos terminaram



Porcentagem de instâncias correlated com 4 objetivos em que cada algoritmo utilizou a menor quantidade de nós do Branch-and-bound




● GS utilizou menor
● FER utilizou menor


● GS utilizou menor quantidade de nós
● FER utilizou menor quantidade de nós

Resultados para 4 objetivos : Quantidade de nós do B&B


Cálculo efetuado sobre o total de instâncias anti-correlated em que ambos os modelos atingiram 3 horas



Cálculo efetuado sobre o total de instâncias anti-correlated em que ambos os modelos terminaram




Porcentagem de instâncias anti-correlated com 4 objetivos em que cada algoritmo utilizou a menor quantidade de nós do Branch-and-bound




● GS utilizou menor quantidade de nós
● FER utilizou menor quantidade de nós

Resultados para 4 objetivos : Quantidade de nós do B&B

Curvas de crescimento da quantidade média de nós em função do tamanho das instâncias correlated com 4 objetivos




Curvas de crescimento da quantidade média de nós em função do tamanho das instâncias anti-correlated com 4 objetivos





Considerações finais e trabalhos complementares


- ❶ O modelo de Galand e Spanjaard (2012) apresentou, no geral, desempenho superior ao de Fernández et al. (2017)
- ❷ Tal diferença de desempenho, contudo, diminui para 4 objetivos, sugerindo que, possivelmente, o modelo proposto por Fernández et al. (2017) possa se tornar mais competitivo com mais objetivos
- ❸ Pesquisa complementar:
 - ❶ experimentos com 5, 8 e 10 objetivos;
 - ❷ testar instâncias com até 50 vértices;
 - ❸ adotar outros critérios para gerar os pesos ω_i , $i \in P$, além do *k-centrum*;
 - ❹ implementar algum dos modelos alternativos de Fernández et al. (2017), o qual reduz o número de restrições, a fim que se possa comparar com os modelos experimentados por este trabalho.

Referências Bibliográficas I


 CHASSEIN, A.; GOERIGK, M. Alternative formulations for the ordered weighted averaging objective. *Information Processing Letters*, Elsevier, v. 115, n. 6, p. 604–608, 2015.


 DE, A.; DIAZ, E. D. A fuzzy ordered weighted average (owa) approach to result merging for metasearch using the analytical network process. In: IEEE. *Emerging Applications of Information Technology (EAIT), 2011 Second International Conference on*. [S.l.], 2011. p. 17–20.


 FERNÁNDEZ, E.; POZO, M. A.; PUERTO, J. Ordered weighted average combinatorial optimization: Formulations and their properties. *Discrete Applied Mathematics*, Elsevier, v. 169, p. 97–118, 2014.


 FERNÁNDEZ, E. et al. Ordered weighted average optimization in multiobjective spanning tree problem. *European Journal of Operational Research*, Elsevier, v. 260, n. 3, p. 886–903, 2017.


Referências Bibliográficas II

 GALAND, L.; SPANJAARD, O. Exact algorithms for owa-optimization in multiobjective spanning tree problems. *Computers & Operations Research*, Elsevier, v. 39, n. 7, p. 1540–1554, 2012.


 KNOWLES, J. *Local-search and hybrid evolutionary algorithms for Pareto optimization*. Tese (Doutorado) — Department of Computer Science, University of Reading, Reading, UK, 2002.


 MAGNANTI, T. L.; WONG, R. T. Network design and transportation planning: Models and algorithms. *Transportation Science*, v. 18, p. 1–55, 1984.

 OGRYCZAK, W.; ŚLIWIŃSKI, T. On solving linear programs with the ordered weighted averaging objective. *European Journal of Operational Research*, Elsevier, v. 148, n. 1, p. 80–91, 2003.

 RAMENTOL, E. et al. Ifrowann: imbalanced fuzzy-rough ordered weighted average nearest neighbor classification. *IEEE Transactions on Fuzzy Systems*, IEEE, v. 23, n. 5, p. 1622–1637, 2015.

Referências Bibliográficas III

 WANG, H.; ZHANG, Y.; QIAN, G. Multiple binary classifiers fusion using induced intuitionistic fuzzy ordered weighted average operator. In: IEEE. *Information and Automation (ICIA), 2011 IEEE International Conference on*. [S.l.], 2011. p. 230–235.

 YAGER, R. R. On ordered weighted averaging aggregation operators in multicriteria decisionmaking. *IEEE Transactions on systems, Man, and Cybernetics*, IEEE, v. 18, n. 1, p. 183–190, 1988.