Proposta de algoritmo genético híbrido para o problema da Árvore Geradora Multiobjetivo baseada no operador *OWA*

Prof^a. Dr^a. Elizabeth Ferreira Gouvêa Goldbarg
Islame Felipe da Costa Fernandes

Departamento de Informática e Matemática Aplicada - DIMAp
Universidade Federal do Rio Grande do Norte - UFRN

Natal, 10 outubro de 2017

Agenda

1. Introdução
2. Algoritmo memético
3. Experimentos computacionais

Introdução

1. Abordaremos a Árvore Geradora Multiobjetivo com critério *OWA*.
2. Objetivos do trabalho: propor um algoritmo genético hibridizado com *simulated annealing* e compará-lo com o melhor exato da literatura (FERNÁNDEZ et al., 2017);
3. Serão relatados experimentos para 39 grafos completos, de 30 a 500 vértices, das classes *correlated* e *anti-correlated* para 10 objetivos.

Algoritmo memético

Algoritmo 1: M-SA - Algoritmo genético hibridizado com SA

```
Entrada: Grafo G(V, E)
Saída: Árvore com melhor custo OWA encontrado
P = getInitialPop(#popSize);
best = ∞;
setBest(P, best);
para g = 1 ... #max_gen faça
    Q = {};
    para r = 1 ... #popSize faça
        Selecione randomicamente p1, p2, p3, p4 em P;
        pai = torneioBinario(p1, p2);
        mae = torneioBinario(p3, p4);
        prob = random(0, 1);
        se prob<#propCross então
            filho = crossover(pai, mae);
        senão
            filho = doRandomWalk()
        fim
        prob = random(0, 1);
        se prop<#propMutation então
            mutation(filho);
        fim
        SA(filho);
        Q = Q ∪ {filho};
    fim
    P = getElite(P ∪ Q);
    setBest(P, best);
    se best não mudar em 5 gerações consecutivas então
        renova(P);
    fim
```

População inicial

- Tamanho: $\#popSize$
- Métodos: *Random Walk* (RAIDL; JULSTROM, 2003) e *rmcPrim* (KNOWLES, 2002)
- Vetores de escalarização ω para o *rmcPrim*:
  - SPEA/R (JIANG; YANG, 2017)
  - *k-centrum* : $k \in [1, M]$, $\omega_1 = ... = \omega_k = 1/k$ e $\omega_{k+1} = ... = \omega_M = 0$.
  - *k-trimmed* : $k \in \left[1, \frac{M}{2}\right[$, $\omega_1 = ... = \omega_k = 0$, $\omega_{k+1} = ... = \omega_{M-k} = \frac{1}{M-2k}$ e $\omega_{M-k} = ... = \omega_M = 0$
  - *Hurwicz* : $\alpha \in \{0.2, 0.3, 0.4, 0.6, 0.7, 0.8\}$, $\omega_1 = \alpha$, $\omega_2 = ... = \omega_{M-1} = 0$ e $\omega_M = 1 - \alpha$.

Operadores genéticos (RAIDL; JULSTROM, 2003)

Figure: Operador *crossover* (RAIDL; JULSTROM, 2003)

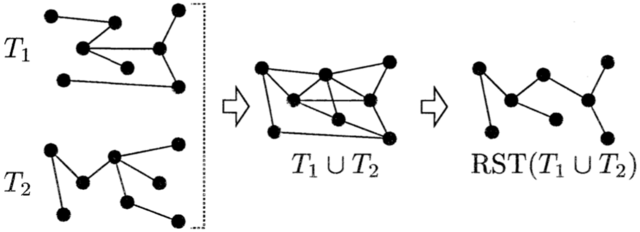

Figure: Operador Mutação (RAIDL; JULSTROM, 2003)

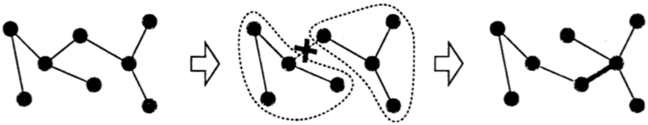

Simulated Annealing

Algoritmo 2: *Simulated Annealing*

```
Entrada: sol: solução, $T_0$: temperatura inicial, $L_0$: quantidade inicial de iterações
$s = sol$;
$T_i = T_0$;
$L_i = L_0$;
enquanto $T_i > 0$ faça
    para $i$=1 ... $L_i$ faça
        escolha randomicamente dois pares de aresta $(v_l, v_{l+1})$ e $(v_j, v_{j+1})$ em $s$;
        remova $(v_l, v_{l+1})$ e $(v_j, v_{j+1})$ de $s$;
        religue os vértices $v_l, v_{l+1}, v_j, v_{j+1}$ e produza $s'$;
        $\Delta C = OWA(s') - OWA(s)$;
        se $\Delta C \leq 0$ então
            $s = s'$;
            se $OWA(s) < OWA(sol)$ então
                $sol = s$;
            fim
        senão
            se $random(0,1) < exp\{-\frac{\Delta C}{T_i}\}$ então
                $s = s'$
            fim
        fim
    fim
    $T_i = \frac{T_i}{F_T}$;
    $L_i = L_i * F_L$;
fim
```

Estratégia de renovação da população

- 50% dos indivíduos substituídos por soluções geradas pelo *rmcPrim* com vetor de escalarização w (pesos OWA da instância)
- 1/3 sofrem mutação

Instâncias

1. 60 instâncias
2. 30 a 500 vértices
3. 10 objetivos
4. 3 grupos de instâncias: $n.1$, $n.2$, $n.3$
5. Classes: *correlated* e *anti-correlated* (KNOWLES, 2002)
    1. *correlated* Coeficientes dos respectivos grupos: 0.2, 0.5 e 0.85
    2. *anti-correlated* Coeficientes dos respectivos grupos: -0.2, -0.5 e -0.85
6. Critério do operador *OWA*: *k-trimmed*
    1. Dado um inteiro $k \in \left[1, \frac{M}{2}\right[$ e atribui-se $\omega_1 = ... = \omega_k = 0$, $\omega_{k+1} = ... = \omega_{M-k} = \frac{1}{M-2k}$ e $\omega_{M-k} = ... = \omega_M = 0$.

Parâmetros

Table: Parâmetros para o *M-SA*

$\#max\_gen = 50$	$T\_0 = 30$
$\#popSize = 100$	$F\_T = 1,8$
$\#propCross = 0,97$	$L\_0 = 15$
$\#propMutation = 0,1$	$F\_L = 1,8$
$\#perTo = 0,03$	$\kappa = 6$

Metodologia dos experimentos

- Para cada instância, 30 execuções
- Dados:
  - Qualidade da solução retornada;
  - Evolução da qualidade ao longo das gerações do processo evolucionário
  - Tempo para atingir a melhor solução
  - tempo total
  - Quantidade de vezes em que a população precisou ser renovada
  - Contribuição dos operadores de *crossover*, mutação e do *SA*.
- Desvio percentual:

$$d_p = \frac{OWA(s_h) - OWA(s_s)}{OWA(s_s)} * 100 \tag{1}$$

onde s_s e s_h são, respectivamente, a solução retornada pelo *solver* e pelo *M-SA*.

Resultado - Qualidade de soluções

- O *solver* atingiu 1 hora em todas as instâncias:
  - Solução factível de 30 a 400 vértices, tanto na classe *correlated* quanto na *anticorrelated*
  - *gap* na classe *correlated*: de $81,68\%$ a 100%
  - *gap* na classe *anticorrelated*: de $84,23\%$ a 100%

Resultado - Qualidade de soluções

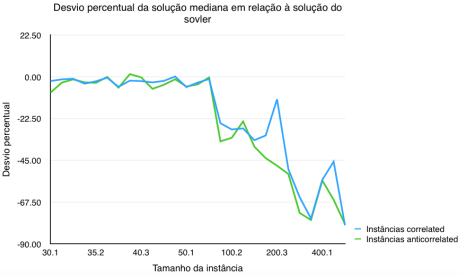

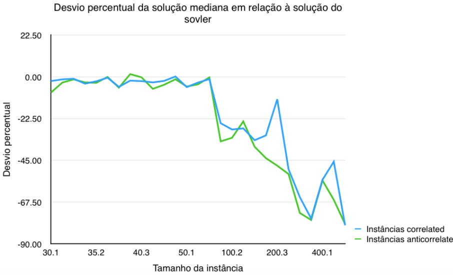

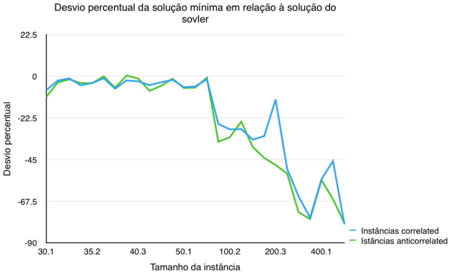

Resultado - taxa de sucesso dos operadores

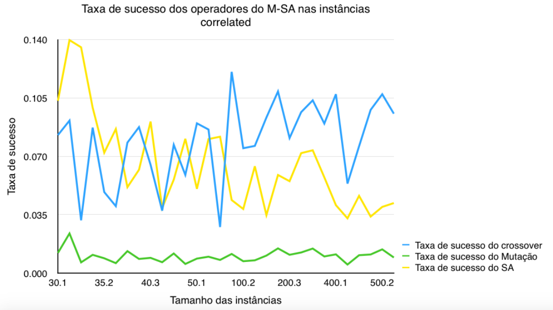

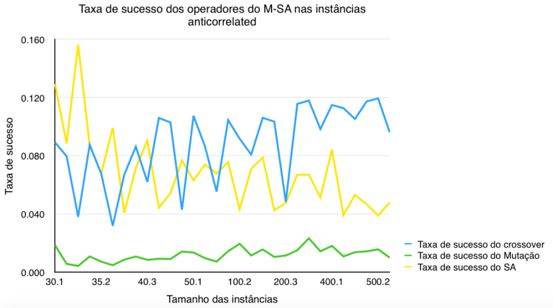

Resultado - Tempo

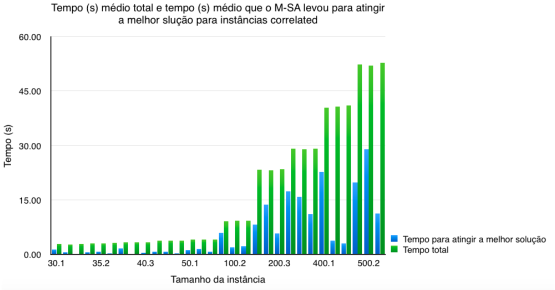

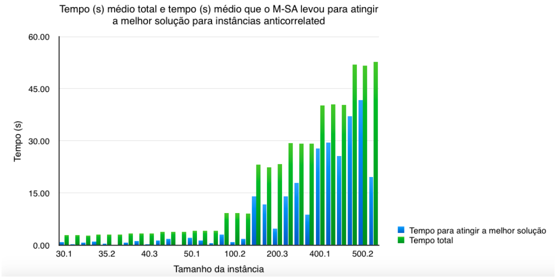

Resultado - Exemplos do evolução

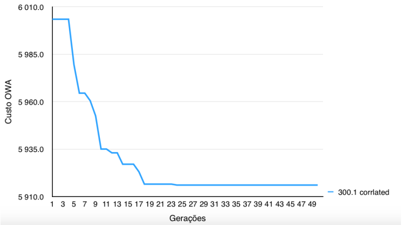

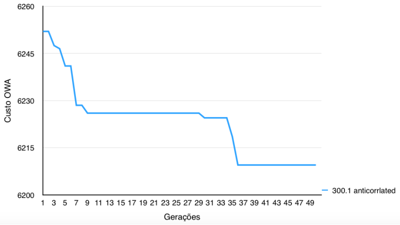

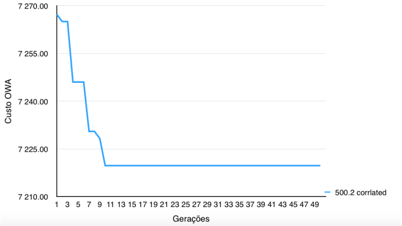

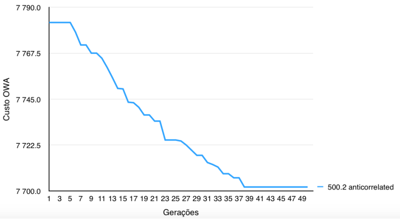

Resultado - Quantidade de renovações

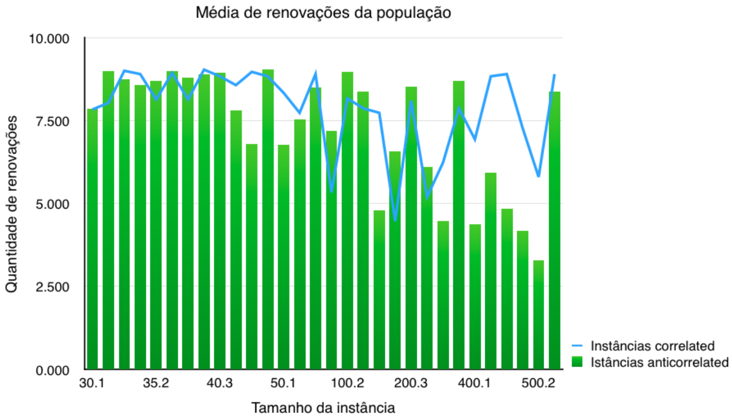

Considerações Finais e trabalhos futuros

- O *M-SA* conseguiu ser melhor que o exato!!
- Evolução algumas vezes foi tímida
- Propor algoritmo transgenético
- Testar com mais instâncias (até 1000 vértices) e outros critérios OWA
- Parâmetros com IRACE

Referências Bibliográficas I

FERNÁNDEZ, E. et al. Ordered weighted average optimization in multiobjective spanning tree problem. *European Journal of Operational Research*, Elsevier, v. 260, n. 3, p. 886–903, 2017.

JIANG, S.; YANG, S. A strength pareto evolutionary algorithm based on reference direction for multiobjective and many-objective optimization. *IEEE Transactions on Evolutionary Computation*, IEEE, v. 21, n. 3, p. 329–346, 2017.

KNOWLES, J. *Local-search and hybrid evolutionary algorithms for Pareto optimization*. Tese (Doutorado) — Department of Computer Science, University of Reading, Reading, UK, 2002.

RAIDL, G. R.; JULSTROM, B. A. Edge sets: an effective evolutionary coding of spanning trees. *IEEE Transactions on Evolutionary Computation*, v. 7, n. 3, p. 225–239, 2003.